Oracle
Regular Expressions 완전정복

➢ 오 동 규 수석 컨설턴트

Copyright (c) Openmade Consulting All rights reserved.

Openmade CONSULTING

오라클 정규식 이란?

강력한 **Text** 분석도구로서 **Like** 의 한계를 극복함.

유닉스의 정규식과 같음.

Pattern-Matching-Rule

다양한 메타문자 제공.

Copyright (c) Openmade Consulting All rights reserved.

Regular Expressions

정규식 기본 **Syntax.**

함수 사용법.

정규식 고급 **Syntax.**

11g New Features

Copyright (c) Openmade Consulting All rights reserved.

정규식의 용도

When

- **ETL/**전환/이행
- **Data Mining**
- **Data Cleansing**
- 데이터 검증

What

- 중복 단어의 확인
- 특별한 상태에서 공백의 제거
- 문자의 파싱**(parsing)**
- **Text** 에서 전화 번호, 우편 번호, 이메일 주소, 주민등록번호, **IP** 주소, 파일 이름, 경로 이름 등을 검증 및 추출
- **HTML** 태그, 숫자, 날짜, 기타 특정 텍스트 데이터와 일치하는 패턴을 확인하고 다른 패턴으로 대체하는 것이 가능
- **Constraints** 로 사용가능

Copyright (c) Openmade Consulting All rights reserved.

Matching a Single Character

.(dot) 는 모든 문자와 match 된다. 단 엔터(new line) 은 예외임.

```
SELECT emp_id,
       REGEXP_SUBSTR(text,'...-....') text
FROM employee_comment
WHERE REGEXP_LIKE(text,'...-....');
```

```
  EMP_ID     TEXT
---------- ----------------
      7369 313-5351
      7499 989-387-
      7521 387-1698
```

989-387- 는 의도되지 않은 결과이다.

Copyright (c) Openmade Consulting All rights reserved.

Matching Any of a Set of Characters

[] maching SET을 이용하여 숫자만 나오게 하자.

```
SELECT emp_id,
        REGEXP_SUBSTR(text,'[0-9][0-9][0-9]-[0-9][0-9][0-9][0-9]') text
FROM employee_comment
WHERE REGEXP_LIKE(text,'[0-9][0-9][0-9]-[0-9][0-9][0-9][0-9]');
```

```
  EMP_ID     TEXT
---------- -----------
      7369 313-5351
      7499 387-4321
      7521 387-1698
```

- 같은 표현 : [0123456789][0123456789][0123456789]-[0123456789][0123456789][0123456789][0123456789]
- [0-9] 를 사용함으로써 코딩량이 줄어들었다. 하지만 여전히 [0-9] 가 반복되고 있다.

Copyright (c) Openmade Consulting All rights reserved.

Matching Any of a Set of Characters-계속

- **Maching set** 해석 시 주의사항
- 다음 표현을 해석하라

[01-3456-9]

0 이거나
1 에서 3 이거나
4 이거나
5 이거나
6 에서 9인 것

- [.] 표현은 문자 하나를 의미함을 기억하자.

Copyright (c) Openmade Consulting All rights reserved.

Matching Repeating Sequences

Quantifier(repeat operator) {}를 이용하여 반복 횟수를 지정 할수 있다.

```
SELECT emp_id,
        REGEXP_SUBSTR(text,'[0-9]{3}-[0-9]{4}') text
FROM employee_comment
WHERE REGEXP_LIKE(text,'[0-9]{3}-[0-9]{4}');
```

```
EMP_ID     TEXT
---------- ------------
      7369 313-5351
      7499 387-4321
      7521 387-1698
```

Quantifier	설명
*	0 회 또는 그 이상 횟수로 매치
?	0 회 또는 1 회 매치
+	1 회 또는 그 이상 횟수로 매치
{m}	정확히 *m* 회 매치
{m,}	최소한 *m* 회 매치
{m, n}	최소 *m* 회, 최대 *n* 회 매치

Copyright (c) Openmade Consulting All rights reserved.

다양한 가능성을 만족해야 한다.

XXX-XXXX 혹은 XXX-XXX-XXX 패턴이 가능하다. 그리고 구분자도 - 뿐만 아니라 , 나 SPACE 가 올 수 있다.

```
SELECT emp_id,
   REGEXP_SUBSTR(text,
   '[0-9]{3}[-. ][0-9]{3}[-. ][0-9]{4}|[0-9]{3}[-. ][0-9]{4}') text
FROM employee_comment
WHERE REGEXP_LIKE(text,
        '[0-9]{3}[-. ][0-9]{3}[-. ][0-9]{4}|[0-9]{3}[-. ][0-9]{4}')
;
```

```
  EMP_ID TEXT
---------- -------------
      7369 989 313-5351
      7499 989-387-4321
      7521 387-1698
      7566 989.387.4444
      7654 231-898-9823
      7698 388-1234
      7844 989-387.5359
      7876 453-9999
```

| 는 OR 를 의미함

Copyright (c) Openmade Consulting All rights reserved.

Subexpressions

지역번호는 괄호() 가 올수 있고 괄호는 생략도 가능하다. 또한 지역번호 자체도 생략될 수 있다.

```
SELECT emp_id,
  REGEXP_SUBSTR(text,
  '([0-9]{3}[-. ]|\([0-9]{3}\) )?[0-9]{3}[-. ][0-9]{4}') text
FROM employee_comment;
```

```
 EMP_ID     TEXT
---------- ---------------
      7369 989 313-5351
      7499 989-387-4321
      7521 387-1698
      7566 989.387.4444
      7654 231-898-9823
      7698 (989) 388-1234
      7782
      7788
      7839
      7844 989-387.5359
      7876 (231) 453-9999
      7900
```

() 는 Grouping expression을 의미함.
?는 생략되거나 1번만 올수 있음.
\ 는 ESCAPE 문자임.

Copyright (c) Openmade Consulting All rights reserved.

Matching a Single Word

마지막 **space** 앞까지만 출력하라

```
SELECT
     REGEXP_SUBSTR('Brighten the corner where you are', '.* ') text
FROM dual;
```

```
text
-------------------------------
Brighten the corner where you
```

- 마지막 space 부터 찾음을 기억하라.
- 그렇다면 첫번째 space 앞까지만 출력 하려면?

Copyright (c) Openmade Consulting All rights reserved.

Check List Chapter 17 - Regular Expressions

• Matching a Single Word

첫 번째 단어를 출력하라.

```
SELECT
  REGEXP_SUBSTR('Brighten the corner where you are', '[^ ]*') text
FROM dual;
```

```
text
--------------------------------
Brighten
```

Copyright (c) Openmade Consulting All rights reserved.

Pattern Matching Modifiers

Mod.	설명	예제
i	대소문자를 구분하지 않는다.	AbCd 가 return REGEXP_SUBSTR('AbCd', 'abcd', 1, 1, 'i')
c	대소문자를 구분한다.	출력되지 않음: REGEXP_SUBSTR('AbCd', 'abcd', 1, 1, 'c')
n	(.) 는 default 로 new line 이 match 되지 않으나 n 옵션을 주면 가능하다.	n 옵션을 빼면 매칭 되지 않음: REGEXP_SUBSTR('a'||CHR(10)||'d', 'a.d', 1, 1, 'n')
m	multi-line mode 로 검색이 가능하다.	ac 가 return, m 옵션을 빼면 매칭되지 않음. REGEXP_SUBSTR('ab'||CHR(10)||'ac', '^a.', 1, 2, 'm')
x	표현식의 whitespace 를 무시하고 match 한다.	abcd 가 return, 생략할 경우 출력되지 않는다. REGEXP_SUBSTR('abcd', 'a b c d', 1, 1, 'x')

Copyright (c) Openmade Consulting All rights reserved.

함수 사용법

함수설명	사용법
REGEXP_LIKE: 정규 표현에 일치하는 조건을 검색	(**source, 표현식**, Matching Modifiers)
REGEXP_SUBSTR: 정규 표현에 일치하는 부분 문자열을 RETURN	(**source, 표현식**, 시작위치, 발생횟수, Matching Modifiers)
REGEXP_REPLACE: 정규 표현에 일치하는 부분을 지정한 다른 문자열로 치환	(**source, 표현식** , replace string, 시작위치, 발생횟수, Matching Modifiers)
REGEXP_INSTR: 정규 표현에 일치하는 부분의 위치값을 RETURN	(**source, 표현식** , 시작위치, 발생횟수, return option, Matching Modifiers)

- 사용법의 파란색 인자는 필수입력 항목임.
- Optional 항목을 추가할 경우 왼쪽부터 추가할 수 있음.

- REGEXP_INSTR는 특이하게 RETURN OPTION 이 있다. 0 은 시작위치를 RETURN 1 은 종료위치를 RETURN 한다. DEFAULT 는 0 임.

Copyright (c) Openmade Consulting All rights reserved.

Using Backreferences

Backreference 와 REGEXP_REPLACE를 이용하여 Ellen Hildi Smith라는 이름을 SPACE 1칸으로 구분해서 각각 Smith, Ellen Hildi로 변환하라.

```
SELECT REGEXP_REPLACE(
       'Ellen Hildi Smith',
       '(.*) (.*) (.*)', '\3, \1 \2') TEXT
  FROM dual
```

```
TEST
--------------------
Smith, Ellen Hildi
```

Copyright (c) Openmade Consulting All rights reserved.

Using Named Character Classes

Character Class	설명
[:alpha:]	알파벳 문자
[:lower:]	소문자 알파벳 문자
[:upper:]	대문자 알파벳 문자
[:digit:]	숫자
[:alnum:]	알파벳/숫자
[:space:]	출력되지 않는 공백 문자(carriage return, newline, vertical tab, form feed) 등
[:punct:]	구두점 기호
[:cntrl:]	(출력되지 않는) 컨트롤 문자
[:print:]	출력 가능한 문자

Copyright (c) Openmade Consulting All rights reserved.

REGEXP_LIKE

Data 검증예제:
우편번호 컬럼에서 숫자가 아닌 문자가 포함되어 있는 **row** 를 찾아라.

```
SELECT zip
 FROM zipcode
WHERE  REGEXP_LIKE(zip, '[^[:digit:]]')
```

```
ZIP
-----
ab123
123xy
007ab
abcxy
```

Copyright (c) Openmade Consulting All rights reserved.

REGEXP_INSTR

Data 에서 특정 위치 찾기:
SOURCE 에서 숫자 XXXXX 로 끝나거나 XXXXX-XXXX 로 끝나는 지점의 위치를 찾아라.

```
SELECT REGEXP_INSTR(
        'Joe Smith, 10045 Berry Lane, San Joseph, CA 91234-1234',
        ' [[:digit:]]{5}(-[[:digit:]]{4})?$'
                                ) AS starts_at
FROM dual
```

```
STARTS_AT
----------
        44
```

Quantifier	설명
*	0 회 또는 그 이상 횟수로 매치
?	0 회 또는 1 회 매치
+	1 회 또는 그 이상 횟수로 매치
{m}	정확히 *m* 회 매치
{m,}	최소한 *m* 회 매치
{m, n}	최소 *m* 회, 최대 *n* 회 매치

Copyright (c) Openmade Consulting All rights reserved.

REGEXP_SUBSTR

Data 에서 특정부분 발췌하는 예제:
comma를 검색하고 그 뒤에 space 한번이 나오고 계속하여 comma가 아닌 문자가 1 회 또는 그 이상 반복되는 패턴을 검색한 후 마지막으로 또 다른 쉼표를 검색 해야 한다.

```
SELECT REGEXP_SUBSTR(
            'first field, second field , third field',
            ', [^,]+,`
                                  ) as test
  FROM dual
```

```
TEST
------------------
, second field   ,
```

Copyright (c) Openmade Consulting All rights reserved.

REGEXP_REPLACE

Data 에서 특정부분을 제거하여 발췌하는 예제:
아래 source 에서 Space 2칸 이상을 space 1칸으로 만들어라.

```
SELECT REGEXP_REPLACE(
            'Joe   Smith',
            '( ){2,}'
            ' ') AS RX_REPLACE
FROM dual
```

```
RX_REPLACE
----------
Joe Smith
```

이것을 REPLACE 함수를 사용할 경우 아래처럼 나타낼수 있다.

```
SELECT REPLACE('Joe   Smith',`   ', ' ') AS REPLACE
  FROM dual
```

하지만 SPACE 2칸을 지정하였기 때문에 3칸 이상은 수행되지 않는다.

Copyright (c) Openmade Consulting All rights reserved.

REGEXP_COUNT

Data 에서 특정부분이 반복되는 COUNT 를 RETURN 한다.

```
SELECT REGEXP_COUNT(
            'http://scidb.tistory.com',
            '.', 1, 'i') AS "Count TEST"
FROM dual ;
```

11g New feature

```
Count TEST
----------
         2
```

•문법

(**source, 표현식**, 시작위치, Matching Modifiers)

•10g 에서 구현하기.

LENGTH(string) - LENGTH(REPLACE(string, 'i'))

Copyright (c) Openmade Consulting All rights reserved.

Subexpression to Return 파라미터

() 를 이용하여 return 되는 집합을 선택할 수 있다.
Subexpression 중에서 2번째 집합을 return 하라.

```
SELECT REGEXP_SUBSTR(
          'www.oracle-developer.net',
          '(₩.)([a-z-]+)(₩.)', --> subexpressions 을 사용한 표현식
          1,                   --> 시작위치
          1,                   --> 발생횟수
          'i',                 --> Matching Modifiers
          2                    --> 11g: subexpression to return
          ) AS url_middle_11g
FROM   dual;
```

```
URL_MIDDLE_11G
----------------
oracle-developer
```

- 11g New feature
- REGEXP_SUBSTR 와 REGEXP_INSTR 만 가능함

10g 에서 구현하기:

```
REPLACE( REGEXP_SUBSTR('www.oracle-developer.net',  '₩.[a-z-]+₩.'),
     '.')
```

Copyright (c) Openmade Consulting All rights reserved.

정리

1. **Dot** 사용법
2. **[] maching set** 사용법
3. **{}** 를 이용하여 반복 횟수 제어하기
4. **|** 를 이용하여 다양한 조건 만족하기
5. **Subexpression ()** 를 이용하여 **group** 표현 식으로 나타내기
6. **Anchoring(**시작 및 종료**)** 문자 이용하기
7. **Matching a Single Word**

Copyright (c) Openmade Consulting All rights reserved.

정리

- Pattern Matching Modifiers
- REGEXP_INSTR
- REGEXP_LIKE
- REGEXP_REPLACE
- REGEXP_SUBSTR
- REGEXP_COUNT

Copyright (c) Openmade Consulting All rights reserved.

Check List Chapter 17 - Regular Expressions

정리

1. Using Backreferences

2. Using Named Character Classes

3. 11g New Features

   REGEXP_COUNT

   Subexpression to Return 파라미터

4. REGEXP_LIKE와 REGEXP_COUNT를 제외하면 Function Based Index 를 만들 수 있고 Constraint 로 활용가능 하다.

Copyright (c) Openmade Consulting All rights reserved.

별첨

- 정규식 **Metacharacters** 정리**.doc**

감사합니다.

Copyright (c) Openmade Consulting All rights reserved.